

Conception d'un modèle prédictif basé sur l'IA pour l'identification précoce des étudiants à risque d'échec scolaire

Aly lama dia, Boubacar Barry, Fatimata Ba

22 juillet 2025

PLAN

1 Introduction

PLAN

- 1 Introduction
- 2 Présentation des données

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes
- 6 Entraînement des modèles

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes
- 6 Entraînement des modèles
- 7 Déploiement du meilleur modèle

INTRODUCTION



Présentation des données

Source des données et objectif

Source des données

Kaggle, format CSV avec 649 observations et 33 variables incluant des caractéristiques démographiques, sociales et scolaires.


Objectif

Analyser les facteurs influençant la performance académique, identifier les corrélations entre les variables et les notes et construire des modèles qui pourront prédire la moyenne du troisième trimestre d'un individu.


Nettoyage et préparation des données

- **Vérification des données** : Aucune valeur manquante ni doublon détecté dans le jeu de données.
- **Tests de normalité** : Les tests de Skewness, Kurtosis et Shapiro-Wilk confirment la non-normalité des distributions.
- **Identification des valeurs aberrantes** : Plusieurs variables présentent des valeurs extrêmes, visualisées par des boxplots.
- **Traitement des anomalies** : Les valeurs aberrantes peuvent être remplacées par les bornes pour améliorer l'analyse.

Distribution des données



Distribution des données



Distribution des données

Variable	Skewness (Asymétrie)	Kurtosis
age	0.42 (droite)	3.06 (leptokurtique)
traveltime	1.25 (droite)	4.13 (leptokurtique)
studytime	0.69 (droite)	3.03 (leptokurtique)
failures	3.08 (droite)	12.70 (leptokurtique)
absences	2.02 (droite)	8.71 (leptokurtique)
G1	-0.01 (gauche)	3.02 (leptokurtique)
G2	-0.36 (gauche)	4.63 (leptokurtique)
G3	-0.91 (gauche)	5.68 (leptokurtique)

Distribution des données

Variable	p-value (Shapiro-Wilk)
age	$p = 0.0000$ (non normale)
traveltime	$p = 0.0000$ (non normale)
studytime	$p = 0.0000$ (non normale)
failures	$p = 0.0000$ (non normale)
absences	$p = 0.0000$ (non normale)
G1	$p = 0.0000$ (non normale)
G2	$p = 0.0000$ (non normale)
G3	$p = 0.0000$ (non normale)

Distribution des données







FIG. : Valeurs aberrantes

Distribution des données






Distribution des données





Corrélation entre les variables numériques



Corrélations entre les variables numériques

G1 et G2

Corrélation forte et statistiquement significative (p-value = 0.0000)

G1 et G3

Corrélation forte et statistiquement significative (p-value = 0.0000)

ACP

PC1 (93,7% explique la majorité de la variance et est fortement corrélé avec G1, G2, et G3)


G2 et G3

Corrélation forte et statistiquement significative (p-value = 0.0000)


Résultats de la Corrélation de Spearman

Variable	rho	p-value	Corrélation
age	-0.06	0.1003	Aucune corrélation significative
traveltime	-0.14	0.0002	Corrélation significative
studytime	0.27	0.0000	Corrélation significative
failures	nan	nan	Aucune corrélation significative
absences	-0.16	0.0001	Corrélation significative
G1	0.88	0.0000	Corrélation significative
G2	0.94	0.0000	Corrélation significative
G3	1.00	0.0000	Corrélation significative


vérification de la relation linéaire entre G1 et G3



vérification de la relation linéaire entre G2 et G3



Cercle de correlation(ACP)



Influence des variables catégorielles sur G3




FIG. : Influence du soutien parental sur G3 Cercle de corrélation avec l'ACP

Influence des variables catégorielles sur G3




FIG. : Influence du sex sur G3

Résultats du test de Kruskal-Wallis

Variable	G3	p-value	Relation
school	G3	0.0000	Relation significative
sex	G3	0.0008	Relation significative
address	G3	0.0000	Relation significative
famsize	G3	0.5682	Aucune relation significative
Pstatus	G3	0.9114	Aucune relation significative
Medu	G3	0.0000	Relation significative
Fedu	G3	0.0000	Relation significative
Mjob	G3	0.0000	Relation significative
Fjob	G3	0.0018	Relation significative
reason	G3	0.0000	Relation significative
guardian	G3	0.0185	Relation significative
schoolsup	G3	0.0246	Relation significative
famsup	G3	0.4979	Aucune relation significative
paid	G3	0.1449	Aucune relation significative
activities	G3	0.0416	Relation significative
nursery	G3	0.2164	Aucune relation significative
higher	G3	0.0000	Relation significative
internet	G3	0.0001	Relation significative
romantic	G3	0.0615	Aucune relation significative
famrel	G3	0.0163	Relation significative
freetime	G3	0.0007	Relation significative

Résultats du test de Kruskal-Wallis

Variable	G3	p-value	Relation
goout	G3	0.0007	Relation significative
Dalc	G3	0.0000	Relation significative
Walc	G3	0.0001	Relation significative
health	G3	0.0251	Relation significative

Segmentation des élèves par profil de performance




FIG. : Clusters

Choix des variables pertinentes

Variables en Relation avec G3

D'après les résultats des corrélations et des tests statistiques, les variables suivantes ont une relation significative avec la variable de sortie **G3** :

N°	Variable
1	internet
2	sex
3	higher
4	studytime
5	Medu
6	G1
7	G2

Entrainemnt des modèles

- **SVM**

Les modèles choisis

- **SVM**
- **KNN**

- **SVM**
- **KNN**
- **Decision Tree**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**
- **XGBoost**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**
- **XGBoost**
- **MLP**

Résultats des modèles

Modèle	RMSE	MAE	MedAE	R^2
SVM	0.099	0.227	0.178	0.901
KNN	0.171	0.311	0.206	0.828
Decision Tree	0.277	0.318	0.343	0.723
Random Forest	0.178	0.288	0.213	0.822
XGBoost	0.232	0.329	0.258	0.768
MLP	0.416	0.280	0.198	0.827

Déploiement du meilleur modèle