

Conception et Implémentation d'un système intelligent pour la prédiction de la Note du troisième trimestre et l'identification précoce des étudiants à risque

Boubacar Barry, Fatimata Ba, Aly Lama Dia

23 juillet 2025

PLAN

1 Introduction

PLAN

- 1 Introduction
- 2 Présentation des données

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes
- 6 Entraînement des modèles

PLAN

- 1 Introduction
- 2 Présentation des données
- 3 Nettoyage et préparation des données
- 4 Segmentation des élèves par profil de performance
- 5 Choix des variables pertinentes
- 6 Entraînement des modèles
- 7 Déploiement du meilleur modèle

INTRODUCTION

Présentation des données

Source des données et objectif

Source des données

Kaggle, format CSV avec 649 observations et 33 variables incluant des caractéristiques démographiques, sociales et scolaires.


Objectif

Analyser les facteurs influençant la performance académique, identifier les corrélations entre les variables et les notes et construire des modèles qui pourront prédire la moyenne du troisième trimestre d'un individu.


Nettoyage et préparation des données

Vérification des données : Aucune valeur manquante ni doublon détecté dans le jeu de données.

Distribution des données




Distribution des données





Tests de normalité : Les tests de Skewness, Kurtosis et Shapiro-Wilk confirment la non normalité

Distribution des données



Distribution des données





- **Vérification des outliers** : Plusieurs variables présentent des valeurs extrêmes, visualisées par des boxplots.
- **Correction des outliers** : Les valeurs aberrantes peuvent être remplacées par les bornes pour améliorer l'analyse.

Distribution des données




FIG. : Valeurs abberantes de G1

Distribution des données




FIG. : Valeurs abberantes de G2

Distribution des données






FIG. : Valeurs abberantes de G3


Distribution des données




Corrélation entre les variables numériques



vérification de la relation linéaire entre G1 et G3



vérification de la relation linéaire entre G2 et G3



Influence des variables catégorielles sur G3





FIG. : Influence du sex sur G3

influence du temps d'étude sur G3



Influence des variables catégorielles sur G3




FIG. : Influence du sex sur G3

Segmentation des élèves par profil de performance




FIG. : Clusters

Choix des variables pertinentes

Variables en Relation avec G3

D'après les résultats des corrélations et des tests statistiques, les variables suivantes ont une relation significative avec la variable de sortie **G3** :

N°	Variable
1	internet
2	sex
3	higher
4	studytime
5	Medu
6	G1
7	G2

Entrainemnt des modèles

- **SVM**

- **SVM**
- **KNN**

- **SVM**
- **KNN**
- **Decision Tree**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**
- **XGBoost**

- **SVM**
- **KNN**
- **Decision Tree**
- **Random Forest**
- **XGBoost**
- **MLP**

Résultats des modèles

Modèle	RMSE	MAE	MedAE	R^2
SVM	0.099	0.227	0.178	0.901
KNN	0.171	0.311	0.206	0.828
Decision Tree	0.277	0.318	0.343	0.723
Random Forest	0.178	0.288	0.213	0.822
XGBoost	0.232	0.329	0.258	0.768
MLP	0.416	0.280	0.198	0.827

Déploiement du meilleur modèle